Московский Авиационный Институт
(Национальный Исследовательский Университет)

Факультет информационных технологий и прикладной математики
Кафедра вычислительной математики и программирования

Лабораторные работы по курсу «Информационный поиск»

Студент: Салихов Т. Р.

Группа: М8О-412Б-22

Преподаватель: Кухтичев А. А.

Оценка: _____

Дата: _____

Подпись: _____

Москва, 2025

Содержание

Цель работы

- Составить корпус документов
- Произвести обкачку документов
- Произвести очистку документов: выделить текст статей
- Произвести токенизацию текстов
- Составить булев индекс и реализовать булев поиск по документам
- Составить обратный индекс для TF-IDF и реализовать поиск с использованием TF-IDF для ранжирования

Описание данных

В качестве темы для корпуса документов были выбраны новостные статьи о Формуле 1 на английском языке. В качестве источников данных использовались два крупнейших портала с новостями Формулы 1: motorsport.com и the-race.com. Примеры статей приведены ниже.

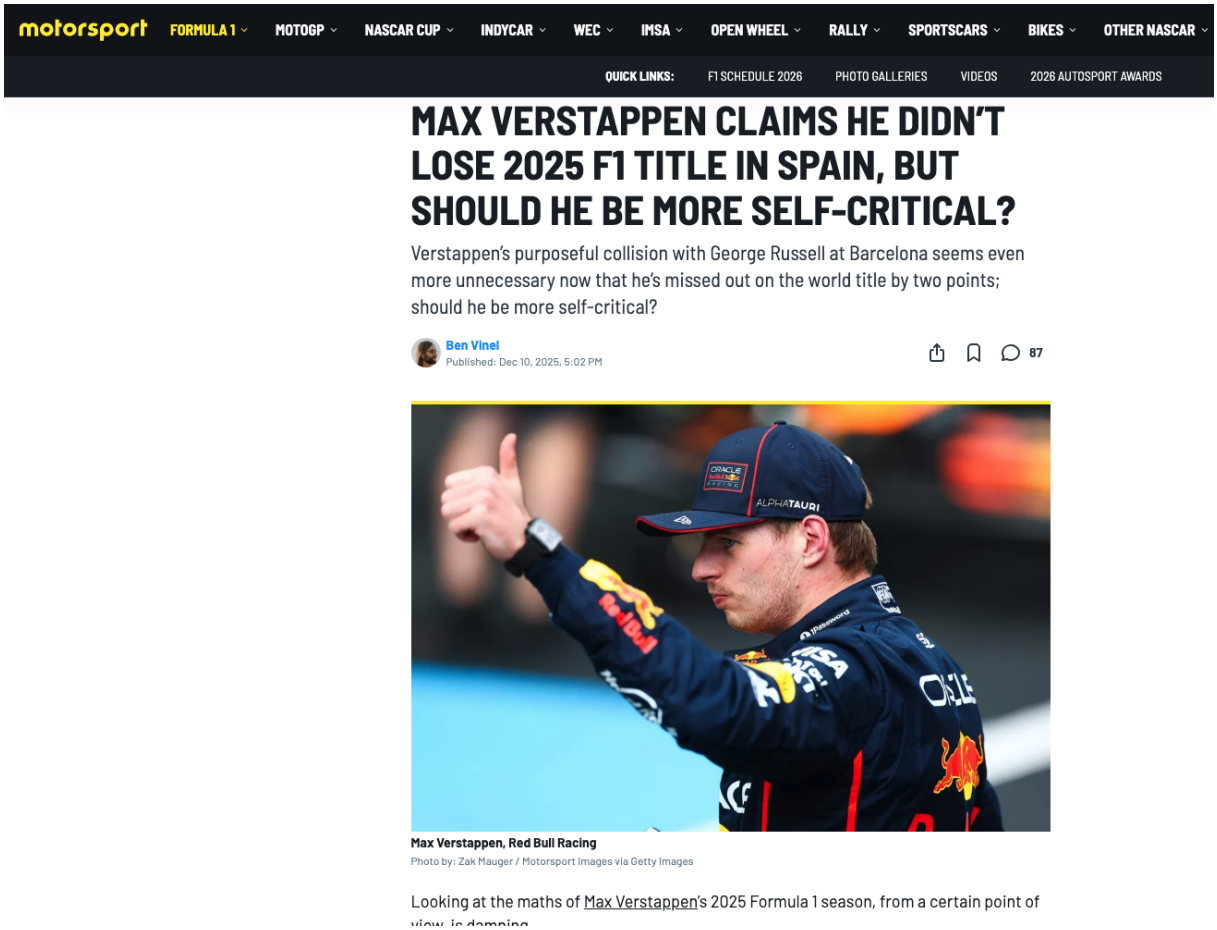

Рис. 1: Пример статьи на motorsport.com

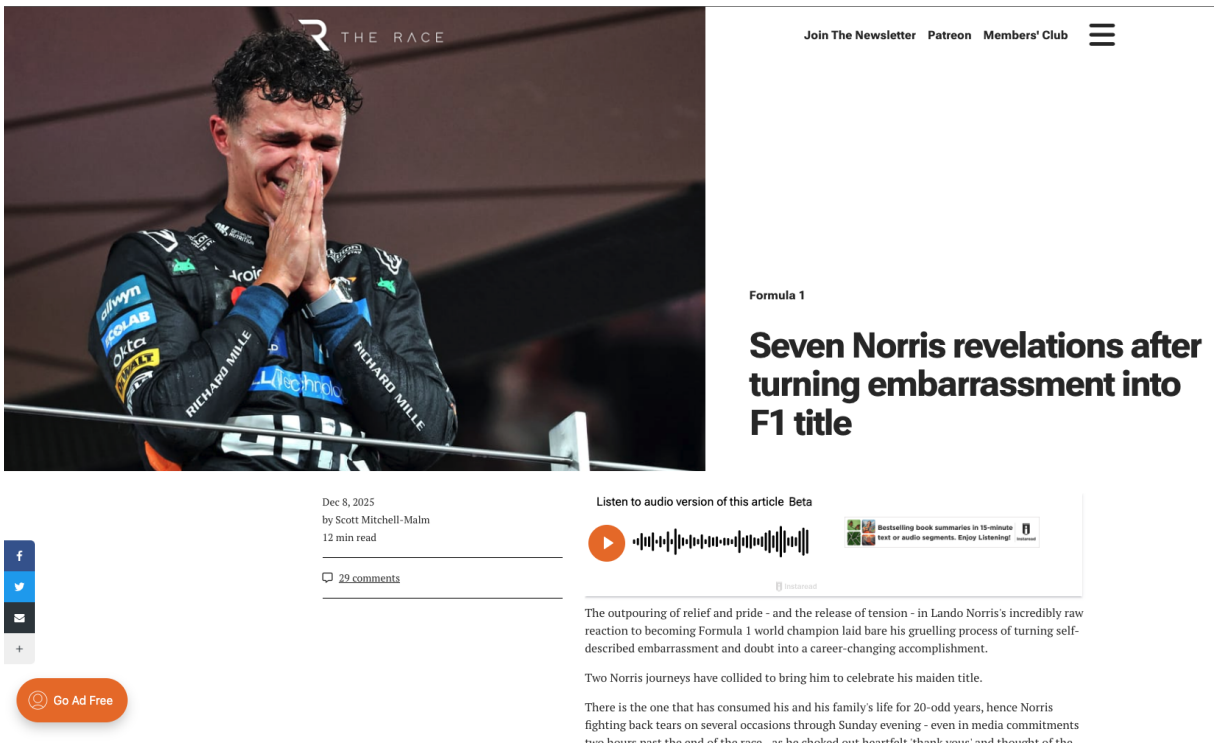

Рис. 2: Пример статьи на the-race.com

Для составления корпуса документов был написан вспомогательный скрипт на языке javascript, который проходит по sitemap.xml обоих ресурсов и составляет список url адресов статей, относящихся к F1.

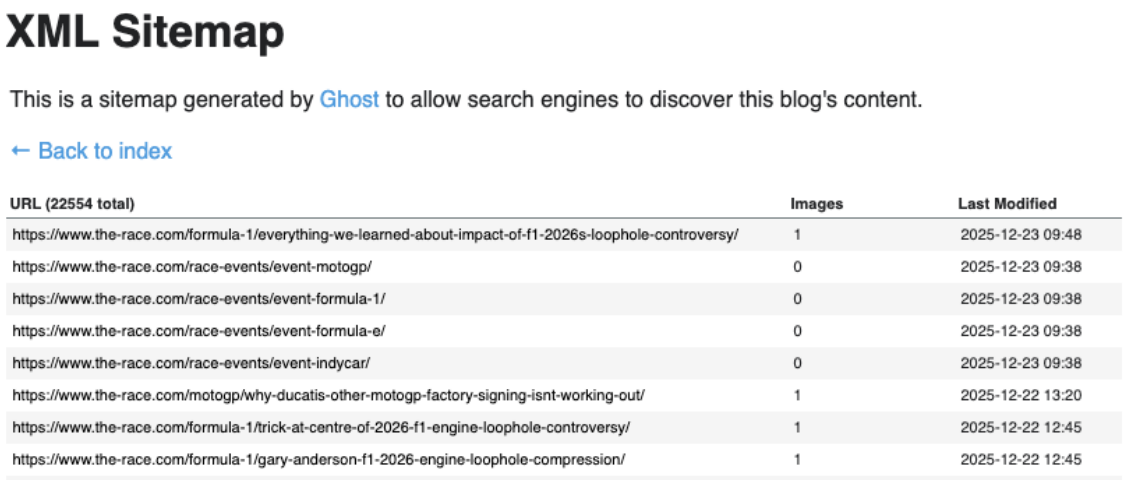

XML Sitemap

This is a sitemap generated by Ghost to allow search engines to discover this blog's content.

← Back to index

URL (22554 total)	Images	Last Modified
https://www.the-race.com/formula-1/everything-we-learned-about-impact-of-f1-2026s-loophole-controversy/	1	2025-12-23 09:48
https://www.the-race.com/race-events/event-motogp/	0	2025-12-23 09:38
https://www.the-race.com/race-events/event-formula-1/	0	2025-12-23 09:38
https://www.the-race.com/race-events/event-formula-e/	0	2025-12-23 09:38
https://www.the-race.com/race-events/event-indycar/	0	2025-12-23 09:38
https://www.the-race.com/motogp/why-ducatis-other-motogp-factory-signing-isnt-working-out/	1	2025-12-22 13:20
https://www.the-race.com/formula-1/trick-at-centre-of-2026-f1-engine-loophole-controversy/	1	2025-12-22 12:45
https://www.the-race.com/formula-1/gary-anderson-f1-2026-engine-loophole-compression/	1	2025-12-22 12:45

Рис. 3: Пример sitemap.xml с the-race.com

В результате составления корпуса документов был получен корпус размером 58689 документов.

Обкачка документов

Для обкачки документов был написан специальный бот на языке javascript. Данный бот получает на вход конфигурационный файл, в котором задаются следующие параметры:

- url базы данных mongo, название базы данных, название коллекции;
- url redis очереди;
- Параметр sources, который указывет путь к файлу с источниками обкачки;
- Параметр mode, который задает режим работы бота: обкачка или обновление.

Для хранения данных о документах на удаленном сервере была развернута база данных mongo. Также для обкачки была реализована redis очередь. Это позволило сделать возможность остановки и продолжения обкачки с того же места при необходимости. Для получения сырых html страниц использовалась библиотека axios. В базу данных записывались следующие данные: url страницы, сырой html код страницы, название источника и дата обкачки. Так как обемы страниц оказались существенными, то в базу данных записывались html страницы в сжатом виде с использованием библиотеки zlib.

Также была предусмотрена возможность запуска бота в режиме обновления. При таком запуске бот проходит по документам в базе данных и если документ не обновлялся в последние 7 дней, бот проверяет, изменился ли источник. При обнаружении изменений в базе данных происходит обновление.

Database Stats	
Collections (incl. system.namespaces)	1
Data Size	5.76 GB
Storage Size	5.86 GB
Avg Obj Size #	98.1 KB
Objects #	58689
Indexes #	2
Index Size	5.88 MB

Рис. 4: Статистика базы данных

Итоговое количество документов в базе данных составило 58689. Общий объем данных 5.76 GB. Средний размер документа 98.1 KB.

Парсинг и токенизация страниц

Парсинг и токенизация осуществлялись на языке C++. Для работы с базой данных был реализован класс DB, осуществляющий взаимодействие с базой данных при помощи библиотек mongocxx и bsoncxx. Для парсинга был написан класс Parser. Данный класс использует внутри библиотеку Gumbo для парсинга сырых html страниц, извлечения из них текстов статей.

При токенизации программа получает курсор на коллекцию с документами в базе данных. Проходя курсором по документам, программа извлекает сжатый html код и разворачивает его при помощи библиотеки zlib. Далее этот сырой код передается методу extract_text класса Parser, который парсит страницу, находит на ней div, в котором содержится статья и извлекает только текст из этого div. Далее текст передается в функцию tokenize, которая производит разбиение текста на массив токенов. Токенизация разбивает текст по словам, при этом учитываются сложные слова, содержащие дефис и апостроф, а также числа и даты. Выход функции копируется в bson массив и записывается в базу данных как поле tokens.

```
{
    _id: ObjectId('693af69424ba3d3e6fd95c9d'),
    url: 'https://www.motorsport.com/f1/news/minardi-testing-at-magny-cours-98-06-18/16826/',
    data: BinData(0, 'H4sIAAAAAAAAE+y967rbNpI2+t9XQas/20sJqUVSZ60ombST9KQ7SWfipHt6bD8eSIQk2hT
    source: 'www.motorsport.com',
    date: 1765471892622,
    tokens: [
        'joint',
        'effort',
        'from',
        'nakano',
        'and',
        'tuero',
        'today',
        'tarmac',
        'temperatures',
        'were',
        'higher',
        'at',
        'magny-cours',
        'circuit',
        'almost',
        '10',
        'what',
        'would',
        'you',
        'like',
        'to',
        'see',
        'on',
        'motorsport.com',
        'the',
        'motorsport.com',
        'team'
    ]
}
```

Рис. 5: Пример токенизированного документа в базе данных

В результате все документы были разбиты на токены. Всего уникальных токенов оказалось 129013, средняя длинна токена около 8.5 символов. Для проверки закона Ципфа частотности всех токенов были рассчитаны и проранжированы по убыванию. Важно уточнить, что при подсчете применялась лемматизация. Далее был построен log-log график зависимости частотности от ранга:

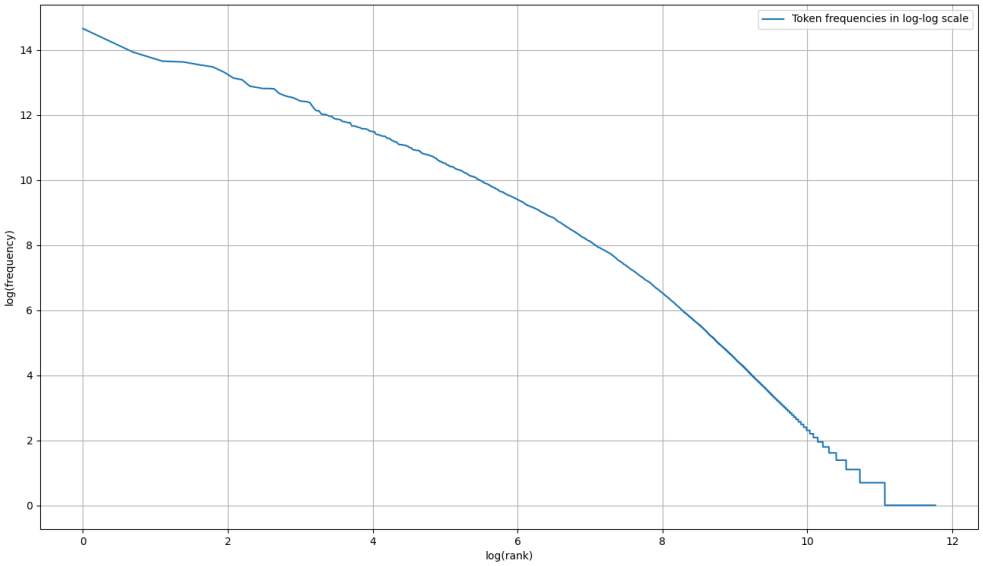

Рис. 6: График зависимости частотности от ранга в log-log шкале

Как можно заметить, график является практически прямой с небольшим отклонением в середине, что доказывает, что корпус документов удовлетворяет закону Ципфа. Хвост в виде лесенки может быть объяснен тем, что помимо слов учитывались так же числа и даты, которые могут быть достаочно уникальными и встречаться крайне редко, из-за чего и формируется такой хвост.

Булев индекс и Булев поиск

Для реализации простейшего Булева поиска необходимо сначала построить Булев индекс. Булев Индекс - обратный индекс, который для каждого токена хранит список документов, в которых он встречается. Для этих целей был реализован класс Indexer, который отвечает за построение индекса. Построение происходит следующим образом:

- Курсор базы данных проходит по всем документам и берет список токенов конкретного документа;
- Далее каждый токен лемматизируется при помощи внутренней функции lemmatize, которая производит лемматизацию с применением библиотеки wordnet;
- Если токена еще нет в индексе, то он туда добавляется, если уже есть, то номер текущего документа добавляется к списку данного токена, при условии, что этот номер не был ранее добавлен.

Таким образом, получается булев индекс. После построения индекс может быть сохранен в бинарный файл с применением сериализации, после чего загружен повторно в другой программе.

Общий объем индекса составил 461 MB. С учетом количества документов требование по памяти составило примерно 3.66 KB/токен. Время построения индекса составило примерно 4.5 часа, что эквивалентно 16.5 мс на документ. Так как для построения индекса применяется поиск по массиву то алгоритмическая сложность составляет порядка $O(n^2)$. Данный показатель можно было бы улучшить до $O(n \log n)$ применив map.

Поиск происходит по следующим правилам:

- Индекс загружается из файла;
- Поисковый запрос пользователя токенизируется и для каждого токена находится соответствующий список документов (При этом обращение к индексу сделано так, что токен автоматически лемматизируется);

- Далее находится пересечение всех списков и выдается пользователю в качестве результата.

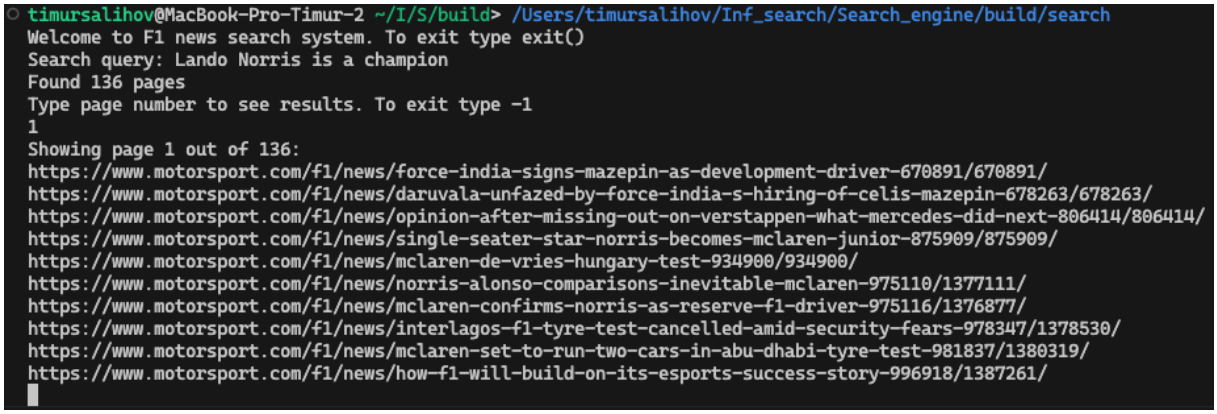

Рис. 7: Пример поискового запроса с Булевым поиском

Подготовка поиска занимает примерно 4.5 секунды. Поисковый запрос выполняется примерно за 1 секунду. Как можно заметить по заголовкам в результатах поиска, статьи не очень подходят под запрос.

TF-IDF и сжатие

Для реализации поиска методом ранжирования по TF-IDF нам понадобится немного модивицировать, а именно для каждого токена хранить не только список документов, в которых он встречается, но и term freauency для каждого из этих документов. Term frequency - сколько раз данный токен встречается в документе. Кроме того, после построения индекса необходимо отсортировать список документов по убыванию tf.

Помимо этого была добавлена возможность сжатия индекса методом Variable Byte. Для этого все уникальные mongo_id были записаны в массив и каждому поставлен в соответствие индекс массива. Таким образом, постинги теперь хранят только индекс массива и tf для данного документа. Так как количество документов не превышает 60000, то все индексы будут не велики. Средний tf также будет достаточно маленьким. Получается, что оба числа можно сжать с 8 байт до 1-2 байт. В таком случае при сериализации сначала сохраняется массив mongo_id, а уже за ним сжатый индекс. Изначальный размер индекса составил 575 MB, то есть примерно 4.56 KB/токен. После сжатия удалось достичь размера индекса 57 MB, то есть примерно 0.45 KB/токен. Таким образом, нам удалось снизить требования по памяти в 10 раз.

Для поиска был реализован класс Scorer, который считает score для каждого документа при каждом токене по следующей формуле:

$$score(token, document) = TF(token, document) * IDF(token),$$

$$TF(token, document) = \log(tf) + 1$$

$$IDF(token) = \log\left(\frac{n+1}{df+1}\right) + 1$$

где tf - как часто данный токен встречается в документе, n - размер корпуса, df - в скольких документах встречается токен.

Поисковый запрос токенизируется и по очереди токены из запроса проходят скоринг. Причем, значения скора при разных токенах складываются. Затем документы сортируются по убыванию скора. Идея в том, что наиболее релевантный документ будет иметь наибольший скор. Важно отметить, что для ускорения были наложены следующие ограни-

чения:

- для каждого токена берется только 100 лучших документов по tf,
- токены, содержащееся более чем в половине документов, отбрасываются.

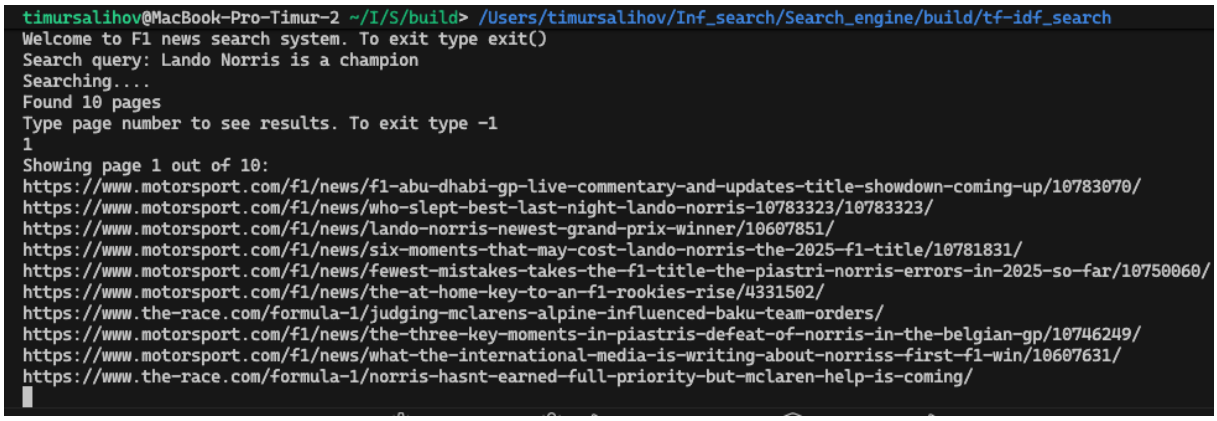

Рис. 8: Пример поискового запроса с TF-IDF

Подготовка поиска занимает примерно 36 секунд. Поисковый запрос выполняется примерно за 1 секунду. Как можем видеть, качество поиска значительно улучшилось и нам стали попадаться намного более релевантные статьи.

Автотесты(юнит-тесты)

Для всех основных модулей программы были написаны юнит-тесты с применением библотеки gtest. Проверялись следующие модули:

- functions - модуль, содержащий вспомогательные функции,
- indexer - модуль, реализующий булев индекс,
- parser - модуль, отвечающий за парсинг страницы,
- scorer - модуль, отвечающий за скоринг TF-IDF,
- tf-idf_indexer - модуль, реализующий TF-IDF индекс

Общий размер тестов составил 35 тестов. Все тесты выполнены без ошибок.

```
[ctest] CTest finished with return code 0
[proc] Executing command: /usr/local/bin/ctest -j4 -C Debug -T test --output-on-failure -R ^tf-idf_indexer_tests$
[ctest] Cannot find file: /Users/timursalihov/Inf_search/Search_engine/build/DartConfiguration.tcl
[ctest]    Site:
[ctest]    Build name: (empty)
[ctest] Cannot find file: /Users/timursalihov/Inf_search/Search_engine/build/DartConfiguration.tcl
[ctest] Test project /Users/timursalihov/Inf_search/Search_engine/build
[ctest]     Start 5: tf-idf_indexer_tests
[ctest] 1/1 Test #5: tf-idf_indexer_tests .............   Passed    0.07 sec
[ctest]
[ctest] 100% tests passed, 0 tests failed out of 1
[ctest]
[ctest] Total Test time (real) =   0.08 sec
[ctest] CTest finished with return code 0
```

Рис. 9: Окно CTest с результатом работы тестов

Вывод

В ходе выполнения работы изучены такие важные аспекты информационного поиска как: токенизация, лемматизация, индексация, булев поиск и поиск с применением ранжирования по TF-IDF. Создан поисковый движок позволяющий искать новостные статьи о Формуле 1.

Ссылка на гитхаб: https://github.com/Demo13B/Info_search